

Modelo Vectorial y Big Data

Modelo vectorial

El modelo vectorial representa cada dato como un vector de números en un espacio de muchas dimensiones. Un texto, una imagen o un audio se convierten en una lista de valores llamada vector de características o embedding. La idea central es que dos datos con significado parecido quedan cerca uno del otro dentro de ese espacio, de modo que buscar información se convierte en medir distancias.

TEXTO $\rightarrow$ MODELO DE EMBEDDING $\rightarrow$ VECTOR $\rightarrow$ ESPACIO VECTORIAL

Por ejemplo, el texto base de datos se convierte en el vector formado por los valores cero punto veintiuno, menos cero punto ochenta y cinco y cero punto cuarenta y siete, dentro de un espacio de n dimensiones.

Representación

Un documento se representa como un vector donde cada dimensión corresponde a un término o a una característica aprendida por el modelo. En el enfoque clásico el valor de cada dimensión se calcula con el peso $TF\ IDF$, que aumenta cuando el término aparece mucho en el documento y disminuye cuando aparece en muchos documentos de la colección. En el enfoque actual los valores los produce una red neuronal y capturan el significado, no solo la palabra escrita.

Medidas de similitud

Similitud coseno. Mide el ángulo entre dos vectores. Su valor va de menos uno a uno y es la medida más usada porque no depende de la longitud del documento.

Distancia euclidiana. Mide la distancia en línea recta entre los extremos de dos vectores. Mientras menor es el valor, mayor es el parecido.

Producto punto. Mide la proyección de un vector sobre otro y toma en cuenta también la magnitud.

La fórmula de la similitud coseno es el producto punto de A y B dividido entre el producto de la magnitud de A por la magnitud de B.

Ángulo entre los vectores	Valor del coseno	Interpretación
---------------------------	------------------	----------------

Cero grados	Uno	Mismo significado
Noventa grados	Cero	Sin relación
Ciento ochenta grados	Menos uno	Significado opuesto

Búsqueda por similitud

La consulta también se convierte en vector y el sistema devuelve los vectores más cercanos, lo que se conoce como búsqueda de los k vecinos más cercanos. Comparar contra todos los vectores es costoso, por lo que se usan índices aproximados como IVFFlat, que agrupa los vectores en listas, y HNSW, que construye un grafo de navegación por capas. Ambos sacrifican algo de exactitud a cambio de mucha velocidad.

CONSULTA → VECTOR DE CONSULTA → ÍNDICE HNSW → K VECINOS MÁS CERCANOS

Modelo vectorial en PostgreSQL

```
CREATE EXTENSION vector;
```

```
CREATE TABLE documento (
  id_doc SERIAL PRIMARY KEY,
  titulo VARCHAR(150),
  contenido TEXT,
  embedding VECTOR(3)
);
```

```
INSERT INTO documento (titulo, contenido, embedding)
VALUES ('Modelo relacional', 'Tablas y llaves', '[0.10, 0.90, 0.30]'),
      ('Modelo vectorial', 'Embeddings', '[0.85, 0.15, 0.60]');
```

```
SELECT titulo, embedding <=> '[0.80, 0.20, 0.55]' AS distancia
FROM documento
ORDER BY distancia
LIMIT 3;
```

```
CREATE INDEX idx_doc_vector ON documento
USING hnsw (embedding vector_cosine_ops);
```

El operador de distancia euclidiana se escribe con el signo menor, un guion y el signo mayor. El operador de distancia coseno se escribe con el signo menor, un igual y el signo mayor. El

operador de producto punto interno se escribe con el signo menor, el símbolo de número y el signo mayor.

Aplicaciones del modelo vectorial

Búsqueda semántica, en la que se encuentran documentos por su significado y no por la palabra exacta. Sistemas de recomendación, en los que se sugieren productos parecidos a los que ya consumió el usuario. Búsqueda de imágenes y audio por contenido. Detección de duplicados y de fraude. Recuperación de contexto para modelos de lenguaje.

Big Data

Big Data es el conjunto de datos cuyo volumen, velocidad y variedad superan la capacidad de las herramientas tradicionales para capturarlos, almacenarlos y analizarlos en un tiempo razonable. No se define por una cantidad fija de información, sino por el momento en que el manejador convencional deja de ser suficiente.

Las cinco uves

Volumen. Cantidad de datos generados, que se mide en terabytes y petabytes.

Velocidad. Rapidez con la que los datos se producen y deben procesarse, en ocasiones en tiempo real.

Variedad. Los datos llegan estructurados, semiestructurados y no estructurados, como tablas, archivos JSON, texto, video y sensores.

Veracidad. Grado de confianza y calidad de los datos, que suelen llegar incompletos o con ruido.

Valor. Beneficio que se obtiene después de analizar los datos, que es el fin de todo el proceso.

Arquitectura general

FUENTES → INGESTA → ALMACENAMIENTO → PROCESAMIENTO → SALIDA

Etapa	Función	Herramientas
Fuentes	Generan el dato	Sensores, redes sociales, sistemas
Ingesta	Reciben el flujo	Kafka, Flume, API
Almacenamiento	Guardan el volumen	HDFS, Data Lake, NoSQL

Procesamiento	Analizan y resumen	MapReduce, Spark, Hive
Salida	Presentan el valor	Reportes, tableros, modelos

Tecnologías

Hadoop. Plataforma que almacena los datos distribuidos en muchas computadoras con el sistema de archivos HDFS y los procesa con MapReduce.

MapReduce. Modelo de programación que divide el trabajo en una fase de mapeo, que transforma los datos en pares de llave y valor, y una fase de reducción, que los agrupa y resume.

Spark. Motor de procesamiento que trabaja en memoria y por eso resulta mucho más rápido que MapReduce para análisis repetitivos.

Bases NoSQL. Almacenes que renuncian a parte del modelo relacional para escalar horizontalmente. Se clasifican en clave valor, documentales, de familias de columnas y de grafos.

Ejemplo de MapReduce

Conteo de palabras sobre los textos dato dato y base dato.

Entrada

"dato dato"

"base dato"

Fase Map

(dato, 1) (dato, 1) (base, 1) (dato, 1)

Fase Shuffle

dato: [1, 1, 1]

base: [1]

Fase Reduce

dato = 3

base = 1

Comparación entre base de datos relacional y Big Data

Criterio	Relacional	Big Data
Estructura	Esquema fijo	Esquema flexible
Volumen	Gigabytes	Terabytes y petabytes

Escalamiento	Vertical	Horizontal
Consistencia	ACID	BASE, consistencia eventual
Lenguaje	SQL	SQL, MapReduce, Spark
Tipo de dato	Estructurado	Estructurado y no estructurado

Relación entre el modelo vectorial y Big Data

Los dos temas se unen en el momento en que hay que analizar grandes volúmenes de información no estructurada. Big Data aporta la infraestructura distribuida que permite almacenar y procesar millones de documentos, y el modelo vectorial aporta la forma de representarlos y de buscarlos por significado. Una base de datos vectorial que trabaja sobre un volumen masivo de embeddings es, en la práctica, una aplicación directa de ambos conceptos.

Conclusión

El modelo vectorial cambia la manera de buscar información, porque deja de comparar palabras exactas y comienza a comparar significados mediante distancias en un espacio numérico. Big Data responde al crecimiento de los datos con almacenamiento y procesamiento distribuido. Los manejadores actuales, como PostgreSQL con la extensión vector, integran ambos enfoques dentro del entorno relacional que ya se conoce.